



## EXAMEN PARCIAL PYTHON

### GBI6-2021II: BIOINFORMÁTICA

Apellidos, Nombres <--- CAMBIE POR LOS QUE CORRESPONDA A SUS DATOS  
Angely Camacho.  
03-08-2022

Color de texto

### REQUERIMIENTOS PARA EL EXAMEN

Utilice de preferencia Jupyter de Anaconda, dado que tienen que hacer un control de cambios en cada pregunta.

Para este examen se requiere dos documentos:

1. Archivo `miningscience.py` donde tendrá dos funciones:
2. Archivo `2022I_GBI6_ExamenPython` donde se llamará las funciones y se obtendrá resultados.

### Ejercicio 0 [0.5 puntos] ✓

Realice cambios al cuaderno de jupyter:

- Agregue el logo de la Universidad
- Coloque sus datos personales
- Escriba una **tabla** con las características de su computador

### Ejercicio 1 [2 puntos]

Cree el archivo `miningscience.py` con las siguientes dos funciones:

i. `download_pubmed` : para descargar la data de PubMed utilizando el **ENTREZ** de Biopython. El parámetro de entrada para la función es el `keyword`. → Guardar

ii. `science_plots` : la función debe

- utilizar como argumento de entrada la data descargada por `download_pubmed`
- ordenar los conteos de autores por país en orden ascendente y
- seleccionar los cinco más abundantes. Con esta selección debe graficar un `pie_plot`. Como guía para el conteo por países puede usar el ejemplo de [MapOfScience \(https://github.com/CSB-book/CSB/blob/master/regex/solutions/MapOfScience\\_solution.ipynb\)](https://github.com/CSB-book/CSB/blob/master/regex/solutions/MapOfScience_solution.ipynb).

iii Cree un docstring para cada función. ✓

Luego de crear las funciones, cargue el módulo `miningscience` como `msc` e imprima `docstring` de la función.

In [1]:

# Escriba aquí su código para el ejercicio 1

```
import miningscience
" "
help(msc.download - pubmed)
help(msc.science - plots)
```

## Ejercicio 2 [2 puntos]

Utilice dos veces la función `download_pubmed` para:

- Descargar la data, utilizando los keyword de su preferencia.
- Guardar el archivo descargado en la carpeta `data`.

Para cada corrida, imprima lo siguiente:

'El número artículos para KEYWORD es: XX' # Que se cargue con inserción de texto o valor que correspondea KEYWORD y XX

In [2]:

# Escriba aquí su código para el ejercicio 2

```
Import os
Import re
a = msc.download_pubmed("dogs")
b = len(a)
print('El número artículo para KeyWORD es:', b)
with open("Data/dogs.txt", "w") as txt:
    txt.write(a)
```

lo mismo  
→ un cat.

## Ejercicio 3 [1.5 puntos]

Utilice dos veces la función `science_plots` para:

- Visualizar un `pie_plot` para cada data descargada en el ejercicio 2.
- Guardar los `pie_plot` en la carpeta `img`

[4]:

```
# Escriba aquí su código para el ejercicio 3
import matplotlib.pyplot as plt
cats = msc.science_plots(a)
with open('img/gatos.png', 'w') as png

dogs = msc.science_plots(v)
plt.savefig('img/perros.png', dpi = 500)
plt.show()
```

## Ejercicio 4 [1 punto]

Interprete los resultados de las figuras del **ejercicio 3**

Escriba la respuesta del ejercicio 5.

Se realizó un árbol filogenético con los Accession list.

## Ejercicio 5 [2 puntos]

Para algún gen de las enzimas que intervienen en la ruta metabólica de la gluconeogénesis (Lista de genes por tipología (<https://www.genome.jp/pathway/map00010+C00068>)), realice lo siguiente: ✓

1. Una búsqueda en la página del NCBI nucleotide (<https://www.ncbi.nlm.nih.gov/nucleotide/>). ✓
2. Descargue el Accession List de su búsqueda y guarde en la carpeta `data`.
3. Cargue el Accession List en este notebook y haga una descarga de las secuencias de los **quince primeros** IDs de la accesión.
4. Arme un árbol filogenético para los resultados del paso 3.
5. Guarde su árbol filogenético en la carpeta `img`
6. Interprete el árbol del paso 4.

entrar a cuadrículas  
con #  
numero de accesion.  
↓  
cargar notebook

usar ese #

In [3]:

```
# Escriba aquí su código para el ejercicio 6
with open('Data/sequence.seq') as file:
    text = file.read()
text = text.split('\n')
text = ','.join(text[:102])
handle = Entrez.efetch(db="nucleotide", rettype="gb", retmode="text", id=text)
(print(handle.url))
records = SeqIO.parse("Data/sequence.gb", "genbank")
count = SeqIO.write(records, "Data/sequence.fasta", "fasta")
clustalw_exe = r"C:\Program file (x86)\Clustal W2\clustalw2.exe"
clustalw_cline = ClustalwCommandline (clustalw_exe, infile="Data/sequence.fasta")
assert os.path.isfile(clustalw_exe), "Clustalw executable is missing or not found).
```

Escriba aquí la interpretación del árbol

## Ejercicio 6 [1 punto]

1. Cree en GitHub un repositorio de nombre GBI6\_ExamenPython.
2. Cree un archivo Readme.md que debe tener lo siguiente:

- Datos personales ✓
- Características del computador ✓
- Versión de Python/Anaconda y de cada uno de los módulos/paquetes y utilizados ~
- Explicación de la data utilizada
- Un diagrama de procesos del módulo miningscience

3. Asegurarse que su repositorio tiene las carpetas data e img con los archivos que ha ido guardando en las preguntas anteriores.
4. Realice al menos 1 control de la versión (commits) por cada ejercicio (del 1 al 5), con un mensaje que inicie como:

Carlitos Alimaña ha realizado el ejercicio 1

Carlitos Alimaña ha realizado el ejercicio 2

...

In [ ]:



Nombre [Apellido, Nombre]:

Construya las funciones del módulo miningscience.py

```
def download_pubmed( key word. ):
```

Este script permite buscar artículos en pubmed por medio de palabras claves. "

```
Entrez.email = 'gualapuro.moises@gmail.com'  
busq = Entrez.read(Entrez.esearch(db="pubmed",  
term = key word,  
usehistory = 'y'))
```

```
webenv = busq["WebEnv"]  
query_key = busq["QueryKey"]  
handle = Entrez.efetch(db="pubmed",  
rettype="medline",  
retmode="text",  
retstart=0,  
retmax=543, webenv=webenv, query_key=query_key)  
data = handle.read()  
dataexp = re.sub(r'\n\s{6}', "", data).  
return dataexp.
```

Nombre [Apellido, Nombre]:

```
def science_plots(
    """
```

) :

```
email = re.sub(r'\s[. _%+~]+@[ \w.-]+\.[a-zA-Z]{1,4}', '', file)
puntos = re.sub(r'\.\d.', ',', email)
numb = re.sub(r'\.\d.', '', puntos)
x=numb[1:].split('PMID-')
```

```
Countries_A=[]
for PMID in x:
    q=PMID.split('\n')
    for fila in q:
        w=fila.split(' ')
        if w[0] == 'AD':
            e=fila.split(',')
            Countries_A.append(e[-1])
```

```
a=0
Countries_B=[0]*len(Countries_A)
for lis in Countries_A:
    bytes(lis,encoding="utf8")
    if lis != "":
        w=lis
        if w[0] == ' ':
            w = re.sub (r'^\s',"",w)
        if w[-1] == ' ':
            w = re.sub (r'\s$',"",w)
        w = re.sub (r'\.$',"",w)
        w = re.sub (r'\s$',"",w)
        Countries_B[a]=w
    a=a+1
```

```
Contries_all=[...]
email = re.sub(r'\s[. _%+~]+@[ \w.-]+\.[a-zA-Z]{1,4}', '', file)
puntos = re.sub(r'\.\d.', ',', email)
numb = re.sub(r'\.\d.', '', puntos)
x=numb[1:].split('PMID-')
```

```
Countries_A=[]
for PMID in x:
    q=PMID.split('\n')
    for fila in q:
        w=fila.split(' ')
        if w[0] == 'AD':
            e=fila.split(',')
            Countries_A.append(e[-1])
```

```
a=0
Countries_B=[0]*len(Countries_A)
for lis in Countries_A:
    bytes(lis,encoding="utf8")
    if lis != "":
        w=lis
        if w[0] == ' ':
            w = re.sub (r'^\s',"",w)
        if w[-1] == ' ':
            w = re.sub (r'\s$',"",w)
        w = re.sub (r'\.$',"",w)
        w = re.sub (r'\s$',"",w)
        Countries_B[a]=w
    a=a+1
```